

别把 Agent 神化

别把 Agent 神化：一次请求、一次工具调用与“自我进化”的真实边界

很多 Agent 的演示都从一句话开始：你说“修这个 bug”，它读文件、跑命令、改代码，再告诉你完成了。过程足够像一个会工作的同事，人很容易接着相信：它已经理解了项目，也许还能从失败里自己变强。

这两个判断之间，隔着不少工程部件。一次请求如何被组装？历史怎样进入本轮？skill、tool、MCP 各做什么？工具结果怎样回到模型？如果 Agent 要改自己的能力，谁来判断改动可信？把这些关系拆开，Agent 就不再像一个神秘黑箱。

本文以我本机核查过的 Codex 客户端与 adapter 链路作例子。不同客户端、服务端与模型的字段细节会不同；有一件事却很稳定：模型每一轮处理的都是一份被组装、更新和裁剪的工作包。

一、用户消息只是工作包的一部分



机制示意：当前任务、规则、工具与状态被组装为本轮工作包

1. context 不是一段聊天记录

① 本轮工作包从多种来源拼出来

在我核查的本机链路中，当前任务以结构化 input 进入请求；稳定的 instructions、工具声明、推理设置和并行工具设置分开携带。**用户消息**只是输入源之一。

把任务交给一位新同事时，你不只会说“修 bug”。你还会给他项目规则、可用工具、上次做到哪里、刚刚一条命令返回了什么。少了规则，他可能越过边界；少了结果，他可能重复已经失败的尝试。

当前任务 + 稳定规则 + 能力目录 + 相关状态 + 工具结果
= 本轮工作包

② context 是工作台，memory 是材料库

context 是模型这一轮实际看得见的工作台。任务、最近对话、工具输出和被注入的规则都在这里，但它受预算和编排策略限制。

memory 更像材料库。会话历史、项目文件、用户偏好、摘要和实验记录都可能被保存，却不会因为“保存过”就自动进入下一轮。系统仍要选择：检索哪段、给多少预算、是否压缩、压缩后怎样回到原始来源。

context 是本轮工作台，memory



美观示意：context 与 memory 的关系

flowchart LR

```
U[用户消息\n 修复并验证 bug] --> O[编排器 / adapter]
M[(memory_store\n 历史摘要、项目约定、旧轨迹)] --> R{检索与筛选}
R --> |相关性 / 来源 / 新鲜度 / 预算| C[本轮 context]
U --> C
T[上一轮 tool_result\n TypeError: run is not a function] --> C
I[稳定 instructions\n 边界、项目规则、输出约束] --> C
C --> B[构造本轮 input[]]
B --> L[模型生成下一步动作]
L --> E[执行器调用 tool]
E --> T2[新的 tool_result]
T2 --> C
T2 -.成功或失败事实.-> M
```

```
classDef fact fill:#e8f5f8,stroke:#197a8c,color:#123;
classDef store fill:#fff6d9,stroke:#b48720,color:#432;
class U,T,T2,I,C,B,L,E fact;
class M,R store;
```

这张图读法很简单：memory_store 只提供候选材料，context 才是模型此刻的工作台；工具结果先回到 context，是否沉淀进 memory 是另一件事。

最常见的误解是“有历史，所以已经学会”。历史只说明材料还在；没有筛选、来源和验证，一段旧摘要也可能只是反复注入的旧猜测。

2. input body 让不同材料各归其位


① 请求体不是一段很长的 prompt

把所有机制都叫作 prompt 很省事，却抹掉了边界。input 更接近这一轮发生了

什么；**instructions** 放稳定行为约束；**tools** 描述可调用能力及参数形状；推理和执行设置影响模型怎样使用这些能力。它们的职责和更新节奏不同。

input body 是节件分工，不

客户陆装配的展式请求 以历史状态 / 受控制支



美观示意：input body 的分层构造

一个便于理解的请求体可以写成下面这样。字段名是教学化的简化表示，不是对所有客户端 wire contract 的硬编码：

```
{
  "instructions": "遵守项目规则；先读取 CURRENT.md；不要越过验证边界",
  "input": [
    {"role": "user", "content": "修复并验证 bug"},
    {"type": "context", "name": "相关项目规则", "content": "..."},
    {"type": "function_call_output", "call_id": "call_17", "content": "TypeError: run is not a function"}
  ],
  "tools": [
    {"type": "function", "name": "read_file", "parameters": {"path": "string"}},
    {"type": "function", "name": "run_command", "parameters": {"command": "string"}}
  ],
  "reasoning": {"effort": "medium"},
  "parallel_tool_calls": false,
  "previous_response_id": "resp_previous"
}
```

字段关系：input 描述本轮发生了什么；instructions 描述必须遵守什么；tools 描述允许请求哪些动作及其参数形状；function_call_output 是执行器回传的事实；previous_response_id 只负责接续状态，不能代替事实筛选。

② 状态展开只负责接续

adapter 可以依据 previous_response_id 或会话链展开此前 input，再转换成上游模型需要的 body。**状态展开**解决“这轮怎样接上上一轮”，并不自动完成“什么是事实”“哪段仍相关”“一次成功如何变成长期规则”。

二、skill、tool、MCP 不在同一个位置



美观示意：skill、tool 与 MCP 的职责分工

flowchart TB

S[skill\n方法与边界：先检查什么、如何复盘、何时停止] --> A[模型选择动作]

D[tools 声明\n名称 + 参数 schema + 权限范围] --> A

P[MCP server\n把外部 tools / resources / prompts 接入目录] --> D

A --> C[tool call\nname + arguments]

C --> X{执行器预检}

X -->|拒绝| F[结构化失败\n未发生外部变化]

X -->|通过| E[真实执行\n文件 / 命令 / 服务]

E --> O[function_call_output\nstdout / stderr / exit code / error]

F --> O

O --> N[下一轮 input[]]

```
classDef method fill:#eaf4ff,stroke:#3274a8,color:#123;
classDef interface fill:#eef8ee,stroke:#39804b,color:#132;
classDef fact fill:#fff3d6,stroke:#b47d19,color:#432;
class S,A method;
class D,P,C,X,E interface;
class F,O,N fact;
```

1. skill 讲方法，tool 提供动作

① skill 不会替模型执行命令

skill 更像可复用的操作手册：面对什么信号，先做哪些检查，哪些边界不能越过，结果如何报告。它影响模型怎样组织行动，但它自己不读文件、不改配置、不发请求。

② tool 是受约束的外部接口

tool 才是模型伸向外部世界的接口卡。模型提出工具名和参数，执行器决定是否

真的执行；成功、超时和异常输出再以结构化结果回到下一轮。模型发出工具调用，不等于动作已经发生。


2. MCP 是接入层，不是万能工具

① 它负责把外部能力接入目录

MCP 可以把外部提供者的 tools、resources 或 prompts 接进能力目录。它像接驳总线，不负责替模型规划任务，也不等于某一个工具的执行结果。

这三者可以这样记：skill 告诉模型“通常怎样做”；tool 规定“允许做什么动作”；MCP 处理“怎样接入一批外部能力”。接上 MCP 不等于权限已经放开；写好 skill 也不能绕过 tool 的参数与权限边界。

三、工具调用为什么必须有回程



美观示意：工具调用、预检、执行与结果回灌

```
sequenceDiagram
    participant M as 模型
    participant R as 执行器
    participant W as 外部世界
    M->>R: tool_call{name, arguments}
    R->>R: 参数 / 权限 / schema 预检
    alt 预检失败
        R-->>M: function_call_output{status:"rejected", reason:"..."}
    else 预检通过
        R->>W: 读取文件、执行命令或访问服务
        W-->>R: stdout / stderr / exit code
        R-->>M: function_call_output{status:"completed", result:"..."}
    end
    Note over M: 下一轮只能依据回灌事实继续行动
```

1. 模型提出动作，执行器决定是否让动作发生

① 预检失败时，外部世界没有变化

模型输出工具调用后，参数、兼容性和权限仍可被预检拒绝。此时应把“没有执行”的原因返回模型。预检能拦住确定性错误，却不能证明任务已经解决。

2. 结果回灌让下一轮能面对现实

① 执行结果必须成为下一轮事实

预检通过后，执行器才真正访问文件、命令行或远端服务。结果不论成功还是失败，都应回灌为结构化输出。没有这条回程，模型只能继续猜；把结果压缩成一句“成功”，模型也很难定位下一步。

四、为什么 ReAct、记忆和 refine 还不等于自进化

1. 它们已经让 Agent 能把任务跑得更长

① 单次任务里的适应很有价值

观察、行动、再观察的循环，让 Agent 能根据工具结果调整下一步。记忆能保留偏好和项目约定；规划、重试能处理更多失败路径。这些机制让 Agent 从一次性文本生成，变成能与外部环境往返的执行系统。

② 轨迹不天然等于经验

一次 retry 成功可能是偶然；一段复盘写得通顺，也可能没有改变下一次行动。

轨迹记录发生过什么，却不自动说明应该修改哪里、这条修改对哪些任务仍成立。

2. refine 把问题推进到工程变更

① 候选更新需要治理

refine 类机制会在任务后读取轨迹，对提示词、记忆、skill 或运行状态提出小步修改。价值不在“又调用一次模型”，而在把临时反思变成候选更新。

候选不是结论。谁冻结修改前状态？谁验证？谁安装？失败后回到哪个版本？一旦改动涉及 skill、tool、配置、模型路由或 runtime，这些问题就比生成一段建议更重要。

② 自评能探索，不能单独终审

同一个模型发现问题、提出改动、评价改动并决定上线，速度很快，风险也集中在同一处。模型自评可以提供方向，却不应独自拥有最终裁决权。

五、可信自进化先是一套可反驳的账本



机制示意：任务回路与改进控制面必须分开，候选不能绕过信任边界

flowchart LR

F[事实\n失败、测试、用户纠正] --> H[假设\n解释为何失败]

H --> C[候选\nconfig / tool / skill / loop]

C --> V[独立 Verifier\n回归、契约、冷探针]

V -->|approved| G[Gate\n快照、原子安装、冒烟]

V -->|rejected| J[拒绝记录\n保留原因与证据]

G --> P[应用后的真实结果]

G -->|失败| RB[rollback\n恢复 before snapshot]

P --> F

RB --> F

J --> H

classDef evidence fill:#e8f5f8,stroke:#197a8c,color:#123;

classDef change fill:#fff4d8,stroke:#b48720,color:#432;

classDef guard fill:#edf7ed,stroke:#39804b,color:#132;

class F,H,J,P,RB evidence;

class C change;

class V,G guard;

这里的关键不是“模型能不能提出修改”，而是候选是否经过独立验证、是否有安装前快照，以及失败后能否回到已知状态。

1. 分清事实、假设与候选

① 失败首先只是观察

工具报错、测试失败、用户纠正和任务停滞都是**事实**，却不会自动说明怎么修。

系统要把解释写成可被推翻的假设，再用最小测试或受控对照检验它。

② 候选改动是一场受限实验

候选应说明修改范围、预期结果、验证入口与回滚对象。验证失败时，失败要能定位到这一次实验，而不是混进后续一连串操作。被拒绝的候选同样应留下来，成为下一轮的证据。

2. 可替换能力需要不可替换的边界

① 学习不该只锁在 prompt 里

工具、skill、配置、模型路由和执行 runtime 都会改变 Agent 行为。不同失败需要不同修复入口：读不到文件可能缺工具，格式总错可能缺 skill，超时可能是配置问题。

② 验证链必须保持独立

Verifier、Gate、回归集和权限边界构成信任根。正在被评估的候选可以被它们检查，却不能先改掉检查规则再宣布通过。

这也是 Loom 想补的控制面：把失败、假设、候选、独立验证、冷应用和回滚放到 Actor 外部。它目前不是通用世界模型，也没有证明任意 Agent 都能稳定改好复杂代码；局部 scheduler 实验更不能外推为整体性能。下一篇将只用 refine skill 冷加载/回滚和 scheduler 案例，逐条说明证据能支持什么。

写在最后

今天的 Agent 已经很会行动。让它可靠成长，难点却不只是模型更聪明，而是让一次行动留下能被检查、复跑、拒绝和撤回的状态。

自进化并不神秘：把失败保留为事实，把解释写成假设，把改动限制为候选，把通过权交给独立验证器。能力可以继续变，现实世界仍然保留最后的否决权。

扩展阅读：

- [Codex 开源客户端的请求组装](#)
- [Model Context Protocol](#)
- [Loom 的实验记录与审计范围](#)